

Modelos Mistos - Exemplo: Orthodont

Vanderly Janeiro

Dep. de Estatística - UEM

Contents

Modelo Linear de Efeitos Mistos (LME) 1

Exemplo: Dados do estudo ortodôntico de Potthoff e Roy (1964) 1

Especificação de um modelo geral 11

Modelo Linear de Efeitos Mistos (LME)

Exemplo: Dados do estudo ortodôntico de Potthoff e Roy (1964)

Os pesquisadores estavam interessados no desenvolvimento das crianças ao longo do tempo.¹ Os dados foram coletados por ortodontistas a partir de radiografias de crânios das crianças. A hipófise e a fissura pterigomaxilar são pontos facilmente localizados nas radiografias. Eles coletaram medidas de crescimento dentário, a distância (mm) do centro da glândula pituitária à fissura pterigomaxilar em 27 crianças (11 meninas e 16 meninos) aos 8, 10, 12 e 14 anos.²

```
library(nlme)
```

```
psych::headTail(Orthodont)
```

##	distance	age	Subject	Sex
## 1	26	8	M01	Male
## 2	25	10	M01	Male
## 3	29	12	M01	Male
## 4	31	14	M01	Male
##	<NA>	<NA>
## 105	24.5	8	F11	Female
## 106	25	10	F11	Female
## 107	28	12	F11	Female
## 108	28	14	F11	Female

```
names(Orthodont)
```

```
## [1] "distance" "age" "Subject" "Sex"
```

```
levels(Orthodont$Sex)
```

```
## [1] "Male" "Female"
```

¹ Source: Potthoff, R. F. and Roy, S. N. (1964), "A generalized multivariate analysis of variance model useful especially for growth curve problems", *Biometrika*, 51, 313–326.

² Ver Seção 1.4.1 de Pinheiro, J.C., and Bates, D.M. (2000)




Figure 1: Crescimento dentário (mm) para meninos e meninas

```
Orthodont$id<- as.factor(rep(1:27, each=4))
```

```
library(latticeExtra)
#xyplot(distance ~ age | Sex, data=Orthodont, type="b",
#       groups = Subject, pch=19)
```

Os perfis por nível de indivíduo são mostrados na Figura 1. Parece que *cada indivíduo* tem aproximadamente uma *tendência linear* com possivelmente *diferentes interceptos e inclinações*.

```
plot(Orthodont)
```




Figure 2: Crescimento dentário (mm) - perfis por indivíduo

Os perfis de nível de sujeito são mostrados na Figura 1. Parece

que *cada indivíduo* tem aproximadamente uma *tendência linear* com possivelmente *diferentes intercepto e coeficientes de inclinação*. Vamos agora discutir o modelo (naive):

$$y_{ij} = \beta_0 + \beta_1 \text{age} + \beta_2 \text{Sex}_F + \beta_3 \text{age} : \text{Sex}_F + \varepsilon_{ij}$$





```
lm.0rt <- lm(distance ~ age + Sex + age:Sex,
data = Orthodont)
summary(lm.0rt)


##
## Call:
## lm(formula = distance ~ age + Sex + age:Sex, data = Orthodont)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.6156 -1.3219 -0.1682  1.3299  5.2469
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   16.3406     1.4162  11.538 < 2e-16 ***
## age           0.7844     0.1262   6.217 1.07e-08 ***
## SexFemale     1.0321     2.2188   0.465  0.643
## age:SexFemale -0.3048     0.1977  -1.542  0.126
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.257 on 104 degrees of freedom
## Multiple R-squared:  0.4227, Adjusted R-squared:  0.4061
## F-statistic: 25.39 on 3 and 104 DF, p-value: 2.108e-12
```

Podemos utilizar este modelo para fazer inferências? Como estão as suposições do modelo?


Observando estes gráficos de resíduo não detectamos nada grave em relação as suposições para o modelo usado. Vamos investigar os resíduos em relação a cada indivíduo.

```
boxplot(resid(lm.0rt) ~ Subject, data = Orthodont, las = 2)
abline(h = 0, col="red", lty="dashed")
```





```
bwplot(getGroups(Orthodont) ~ resid(lm.Ord),
       panel=function(...) {
         panel.abline(v=0, col="red", lty="dashed")
         panel.bwplot(...)}))
```



Pode ser observado que, para muitos indivíduos, os resíduos não

estão em torno de zero. Em alguns casos o modelo subestimou as observações do indivíduo e em outros superestimou. Será que incluindo indivíduo no modelo o problema estará resolvido?

```
lm.Ort.2 <- lm(distance ~ id + age * Sex,
data = Orthodont)

summary(lm.Ort.2)

##
## Call:
## lm(formula = distance ~ id + age * Sex, data = Orthodont)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.8969 -0.6151 -0.0212  0.6141  5.0906
##
## Coefficients: (1 not defined because of singularities)
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   19.1219     1.0988  17.403 < 2e-16 ***
## id2           -4.3750     0.9803  -4.463 2.65e-05 ***
## id3           -3.5000     0.9803  -3.570 0.000611 ***
## id4           -1.1250     0.9803  -1.148 0.254604
## id5           -4.7500     0.9803  -4.845 6.19e-06 ***
## id6           -1.3750     0.9803  -1.403 0.164653
## id7           -4.0000     0.9803  -4.080 0.000107 ***
## id8           -3.8750     0.9803  -3.953 0.000167 ***
## id9           -2.6250     0.9803  -2.678 0.009014 **
## id10          1.7500     0.9803   1.785 0.078078 .
## id11          -4.1250     0.9803  -4.208 6.76e-05 ***
## id12          -3.5000     0.9803  -3.570 0.000611 ***
## id13          -3.5000     0.9803  -3.570 0.000611 ***
## id14          -2.8750     0.9803  -2.933 0.004395 **
## id15          -1.8750     0.9803  -1.913 0.059418 .
## id16          -4.7500     0.9803  -4.845 6.19e-06 ***
## id17          -3.0219     1.6568  -1.824 0.071943 .
## id18          -1.3969     1.6568  -0.843 0.401705
## id19          -0.6469     1.6568  -0.390 0.697262
## id20           0.4781     1.6568   0.289 0.773654
## id21          -1.7719     1.6568  -1.069 0.288116
## id22          -3.2719     1.6568  -1.975 0.051781 .
## id23          -1.3969     1.6568  -0.843 0.401705
## id24          -1.0219     1.6568  -0.617 0.539152
## id25          -3.2719     1.6568  -1.975 0.051781 .
## id26          -5.8969     1.6568  -3.559 0.000633 ***
```

```
## id27          1.9781      1.6568    1.194 0.236069
## age           0.7844      0.0775   10.121 6.44e-16 ***
## SexFemale      NA         NA        NA      NA
## age:SexFemale -0.3048      0.1214   -2.511 0.014097 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.386 on 79 degrees of freedom
## Multiple R-squared:  0.8345, Adjusted R-squared:  0.7759
## F-statistic: 14.23 on 28 and 79 DF,  p-value: < 2.2e-16
```

Usando este modelo houve uma melhora no $R^2_{ajustado}$ passando de 0.4061 para 0.7759, mas podemos confiar neste modelo? Observe que o modelo não pode estimar o efeito de *SexFemale*. Parece o caso de um modelo não identificável.

Este modelo contém parâmetros em excesso, e não estamos interessados em todos esses efeitos, por exemplo: qual o interesse no efeito do indivíduo *id27*? Porém, o modelo, pode nos mostrar que cada indivíduo possui coeficiente de inclinação diferente e a inclusão do indivíduo causou diminuição no erro (de $2.257/104 = 0.02170192$ para $1.386/79 = 0.0175443$)

Seria melhor propor um modelo que:³

- controle cada "indivíduo" sem estimar todos esses parâmetros, ou seja, remover o ruído devido a indivíduo com um *baixo custo*;
- evitar o problema de rank-deficiência do modelo quando fatores aninhados estão presentes.

Uma boa solução é ajustar um modelo linear de efeitos mistos aos dados. Vantagens de usar LMMs:

- você pode controlar o efeito de "indivíduo" às custas de estimar um único parâmetro (ou seja, variância de indivíduo)
- o modelo não é mais *rank-deficiente*.


³ rank-deficiência: neste contexto indica que não há informações suficientes contidas nos dados para estimar o modelo desejado

Antes de implementar um modelo misto, vamos obter um modelo linear independente para cada indivíduo.⁴

```
fm10rth.lis <- lmList(distance ~ age, data = Orthodont)
fm10rth.lis
```

```
## Call:
##   Model: distance ~ age | Subject
##   Data: Orthodont
##
## Coefficients:
##   (Intercept)  age
## M16          16.95 0.550
## M05          13.65 0.850
## M02          14.85 0.775
## M11          20.05 0.325
## M07          14.95 0.800
## M08          19.75 0.375
## M03          16.00 0.750
## M12          13.25 1.000
## M13           2.80 1.950
## M14          19.10 0.525
## M09          14.40 0.975
## M15          13.50 1.125
## M06          18.95 0.675
## M04          24.70 0.175
## M01          17.30 0.950
## M10          21.25 0.750
## F10          13.55 0.450
## F09          18.10 0.275
## F06          17.00 0.375
## F01          17.25 0.375
## F05          19.60 0.275
## F07          16.95 0.550
## F02          14.20 0.800
## F08          21.45 0.175
## F03          14.40 0.850
## F04          19.65 0.475
## F11          18.95 0.675
##
## Degrees of freedom: 108 total; 54 residual
## Residual standard error: 1.31004
summary(fm10rth.lis)
## Call:
```

⁴ Notamos que os intervalos para as intercepções têm a mesma largura, assim como os intervalos para a inclinação em relação à idade. Esta é uma consequência de ter dados balanceados; ou seja, todos os sujeitos foram observados o mesmo número de vezes e nas mesmas idades.



```

## Model: distance ~ age | Subject
## Data: Orthodont
##
## Coefficients:
## (Intercept)
## Estimate Std. Error t value Pr(>|t|)
## M16 16.95 3.288173 5.1548379 3.695247e-06
## M05 13.65 3.288173 4.1512411 1.181678e-04
## M02 14.85 3.288173 4.5161854 3.458934e-05
## M11 20.05 3.288173 6.0976106 1.188838e-07
## M07 14.95 3.288173 4.5465974 3.116705e-05
## M08 19.75 3.288173 6.0063745 1.665712e-07
## M03 16.00 3.288173 4.8659237 1.028488e-05
## M12 13.25 3.288173 4.0295930 1.762580e-04
## M13 2.80 3.288173 0.8515366 3.982319e-01
## M14 19.10 3.288173 5.8086964 3.449588e-07
## M09 14.40 3.288173 4.3793313 5.509579e-05
## M15 13.50 3.288173 4.1056231 1.373664e-04
## M06 18.95 3.288173 5.7630783 4.078189e-07
## M04 24.70 3.288173 7.5117696 6.081644e-10
## M01 17.30 3.288173 5.2612799 2.523621e-06
## M10 21.25 3.288173 6.4625549 3.065505e-08
## F10 13.55 3.288173 4.1208291 1.306536e-04
## F09 18.10 3.288173 5.5045761 1.047769e-06
## F06 17.00 3.288173 5.1700439 3.499774e-06
## F01 17.25 3.288173 5.2460739 2.665260e-06
## F05 19.60 3.288173 5.9607565 1.971127e-07
## F07 16.95 3.288173 5.1548379 3.695247e-06
## F02 14.20 3.288173 4.3185072 6.763806e-05
## F08 21.45 3.288173 6.5233789 2.443813e-08
## F03 14.40 3.288173 4.3793313 5.509579e-05
## F04 19.65 3.288173 5.9759625 1.863600e-07
## F11 18.95 3.288173 5.7630783 4.078189e-07
## age
## Estimate Std. Error t value Pr(>|t|)
## M16 0.550 0.2929338 1.8775576 6.584707e-02
## M05 0.850 0.2929338 2.9016799 5.361639e-03
## M02 0.775 0.2929338 2.6456493 1.065760e-02
## M11 0.325 0.2929338 1.1094659 2.721458e-01
## M07 0.800 0.2929338 2.7309929 8.511442e-03
## M08 0.375 0.2929338 1.2801529 2.059634e-01
## M03 0.750 0.2929338 2.5603058 1.328807e-02
## M12 1.000 0.2929338 3.4137411 1.222240e-03
## M13 1.950 0.2929338 6.6567951 1.485652e-08

```



```
## M14    0.525  0.2929338 1.7922141 7.870160e-02
## M09    0.975  0.2929338 3.3283976 1.577941e-03
## M15    1.125  0.2929338 3.8404587 3.247135e-04
## M06    0.675  0.2929338 2.3042752 2.508117e-02
## M04    0.175  0.2929338 0.5974047 5.527342e-01
## M01    0.950  0.2929338 3.2430540 2.030113e-03
## M10    0.750  0.2929338 2.5603058 1.328807e-02
## F10    0.450  0.2929338 1.5361835 1.303325e-01
## F09    0.275  0.2929338 0.9387788 3.520246e-01
## F06    0.375  0.2929338 1.2801529 2.059634e-01
## F01    0.375  0.2929338 1.2801529 2.059634e-01
## F05    0.275  0.2929338 0.9387788 3.520246e-01
## F07    0.550  0.2929338 1.8775576 6.584707e-02
## F02    0.800  0.2929338 2.7309929 8.511442e-03
## F08    0.175  0.2929338 0.5974047 5.527342e-01
## F03    0.850  0.2929338 2.9016799 5.361639e-03
## F04    0.475  0.2929338 1.6215270 1.107298e-01
## F11    0.675  0.2929338 2.3042752 2.508117e-02
##
```

```
## Residual standard error: 1.31004 on 54 degrees of freedom
```

```
par(mfrow=c(1,2))
pairs(fm10rth.lis, id = 0.01, adj = -0.5)
```



```
pairs(fm20rth.lis, id = 0.01, adj = -0.5)
```

```
layout(1)
```

Finalmente, vemos que o padrão nos indivíduos, os intervalos dos interceptos é quase um reflexo do padrão dos intervalos dos coeficientes de inclinação. Segundo Pinheiro e Bates (2000)⁵, isso ocorre porque todos os dados foram coletados entre as idades de 8 e 14 anos, mas o intercepto representa uma distância na idade de 0 (zero). A extrapolação de volta para a idade de 0 resultará em uma alta correlação negativa (cerca de -0.98) entre as estimativas dos coeficientes de inclinação e sua estimativa de intercepto correspondente.

Para removermos isso ajustamos a distância como uma função linear da $(age - 11)$, de modo que os dois coeficientes sendo estimados são a distância aos 11 anos.

```
fm20rth.lis <- update(fm10rth.lis, distance ~ I(age - 11))
plot(intervals(fm20rth.lis))
```



⁵ Pinheiro e Bates (2000), Seção 4.1.1 - pág. 141




Figure 3: Estimativas para intercepto e coeficiente angular considerando (age - 11)

Para continuar com a análise desses dados, poderíamos ajustar um modelo de regressão aos dados centralizados com uma taxa de crescimento comum, mas interceptos diferentes para cada indivíduo.

Especificação de um modelo geral

Um modelo geral é dado por:

$$\begin{aligned} y_{ti} = & \beta_0 + \beta_1(age_{ti} - 11) + \beta_2 Sex_{Fi} + \beta_3(age_{ti} - 11) \times Sex_{Fi} + \left. \vphantom{\beta_0} \right\} \text{Fixo} \\ & u_{0i} + u_{1i} + \varepsilon_{ti} \left. \vphantom{\beta_0} \right\} \text{aleatório} \end{aligned} \quad (1)$$

com a distância (y_{ti}) sendo o resultado na idade $6 + 2t$ ($t = 1, \dots, 4$) para a i -ésima criança ($i = 1, \dots, 27$) e sex_i é o sexo da criança.

Usando esta especificação de modelo, notamos:

- O termo u_{0i} representa a intercepto aleatória.
- O termo u_{1i} representa a inclinação aleatória (efeito aleatório associado com a inclinação para a criança i).

Assumimos que a distribuição dos efeitos aleatórios associados à criança i , u_{0i} e u_{1i} é bivariada normal:

$$\mathbf{u}_i = \begin{pmatrix} u_{0i} \\ u_{1i} \end{pmatrix} \stackrel{iid}{\sim} N_2(\mathbf{0}, \mathbf{D}) \quad \mathbf{D} = \begin{pmatrix} \sigma_{int}^2 & \sigma_{int,inc} \\ \sigma_{int,inc} & \sigma_{inc}^2 \end{pmatrix}$$

e

$$\boldsymbol{\varepsilon}_i = \begin{pmatrix} \varepsilon_{1i} \\ \varepsilon_{2i} \\ \varepsilon_{3i} \\ \varepsilon_{4i} \end{pmatrix} \stackrel{iid}{\sim} N_4(\mathbf{0}, \mathbf{R}_i)$$

e podemos considerar duas diferentes estruturas de covariância dentro da unidade:

- $\mathbf{R}_i = cov(\mathbf{e}_i) = \sigma^2 \mathbf{I}_4$ for both groups
- $\mathbf{R}_i = cov(\mathbf{e}_i) = \sigma_{male}^2 \mathbf{I}_4$ para garotas e $\mathbf{R}_i = cov(\mathbf{e}_i) = \sigma_{female}^2 \mathbf{I}_4$ para garotos.

Forma matricial do modelo para as observações da i -ésima criança:

$$\mathbf{Y}_i = \mathbf{X}_i \boldsymbol{\beta} + \mathbf{Z}_i \mathbf{u}_i + \boldsymbol{\varepsilon}_i, \quad i = 1, \dots, 27$$

sendo

$$Y_i = \begin{pmatrix} Y_{1i} \\ Y_{2i} \\ Y_{3i} \\ Y_{4i} \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix}$$

$$X_i = \begin{pmatrix} 1 & -3 & 0 & 0 \\ 1 & -1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 3 & 0 & 0 \end{pmatrix} \quad \text{ou} \quad X_i = \begin{pmatrix} 1 & -3 & 1 & -3 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & 1 & 1 \\ 1 & 3 & 1 & 3 \end{pmatrix}$$

O primeiro se refere ao masculino.
Os fatores estão a favor do sexo feminino.
Impacta nas colunas 3 e 4 dos X

se a i -ésima criança é masculina ou feminina, respectivamente. Para os termos aleatórios temos:

$$Z_i = \begin{pmatrix} 1 & -3 \\ 1 & -1 \\ 1 & 1 \\ 1 & 3 \end{pmatrix}, \quad u_i = \begin{pmatrix} u_{0i} \\ u_{1i} \end{pmatrix} \quad \text{e} \quad \varepsilon_i = \begin{pmatrix} \varepsilon_{1i} \\ \varepsilon_{2i} \\ \varepsilon_{3i} \\ \varepsilon_{4i} \end{pmatrix}$$

em que $u_i \stackrel{iid}{\sim} N_2(\mathbf{0}, D)$ e $\varepsilon_i \stackrel{iid}{\sim} N_4(\mathbf{0}, R_i)$, com u_i e ε_i independentes entre si.

Reescrevendo o modelo na forma matricial para todas as crianças:

$$Y = X\beta + Zu + \varepsilon$$

em que (com $n = 27 \times 4 = 108$)

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_{27} \end{pmatrix}, \quad X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_{27} \end{pmatrix}, \quad Z = \begin{pmatrix} Z_1 & & & \\ & Z_2 & & \\ & & \ddots & \\ & & & Z_{27} \end{pmatrix}$$

$$u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_{27} \end{pmatrix}, \quad \text{e} \quad \varepsilon_i = \begin{pmatrix} \varepsilon_{1i} \\ \varepsilon_{2i} \\ \varepsilon_{3i} \\ \varepsilon_{4i} \end{pmatrix}$$

Temos então que, Y é um vetor (108×1), X uma matriz (108×4), Z uma matriz (108×54), u um vetor (54×1) e ε um vetor (108×1). Dessa forma:

$$u \stackrel{iid}{\sim} N_2(\mathbf{0}, G) \quad \text{e} \quad \varepsilon \stackrel{iid}{\sim} N(\mathbf{0}, R)$$

em que

$$G = \begin{pmatrix} D & & & \\ & D & & \\ & & \ddots & \\ & & & D \end{pmatrix}, \text{ e } R = \begin{pmatrix} R_1 & & & \\ & R_2 & & \\ & & \ddots & \\ & & & R_{27} \end{pmatrix}. \quad (2)$$

Tal como Pinheiro e Bates (pág. 142), nós ajustamos o modelo

```
fm20rth.lis <- update(fm10rth.lis, distance ~ I(age - 11))
```

O ajuste de um modelo linear misto simples para os dados Orthodont:⁶ ⁶ Apresentado por Pinheiro e Bates na seção 4.2.1 (pág. 146)

```
fm10rth.lme <- lme( distance ~ I(age-11), data = Orthodont,
                  random = ~ I(age-11) | Subject )
summary(fm10rth.lme)
```

```
## Linear mixed-effects model fit by REML
## Data: Orthodont
##      AIC      BIC    logLik
## 454.6367 470.6173 -221.3183
##
## Random effects:
## Formula: ~I(age - 11) | Subject
## Structure: General positive-definite, Log-Cholesky parametrization
##           StdDev   Corr
## (Intercept) 2.1343289 (Intr)
## I(age - 11) 0.2264278 0.503
## Residual    1.3100402
##
## Fixed effects: distance ~ I(age - 11)
##           Value Std.Error DF  t-value p-value
## (Intercept) 24.023148 0.4296601 80 55.91198      0
## I(age - 11) 0.660185 0.0712533 80 9.26533      0
## Correlation:
##           (Intr)
## I(age - 11) 0.294
##
## Standardized Within-Group Residuals:
##           Min           Q1           Med           Q3           Max
## -3.223106868 -0.493760901 0.007316482 0.472151218 3.916031759
##
## Number of Observations: 108
## Number of Groups: 27
```

$y_{ij} = B_0 + B_1(\text{Age}-11)$ [Parte fixa] +
 $U_{0i} + U_{1i} + E_{ij}$ [Parte aleatoria]

$\text{random} = \sim 1 \mid \text{Subject} \rightarrow$ Efeito apenas intercepto
 $\text{random} = \sim I(\text{Age} - 11) \mid \text{Subject} \rightarrow$ Efeito no intercepto e efeito de inclinacao

```
fm10rth.lme <- lme( distance ~ I(age-11), data = Orthodont )
summary(fm10rth.lme)
```

```

## Linear mixed-effects model fit by REML
##   Data: Orthodont
##       AIC      BIC    logLik
##   454.6367 470.6173 -221.3183
##
## Random effects:
##   Formula: ~I(age - 11) | Subject
##   Structure: General positive-definite
##           StdDev   Corr
## (Intercept) 2.1343328 (Intr)
## I(age - 11) 0.2264275 0.503
## Residual    1.3100394
##
## Fixed effects: distance ~ I(age - 11)
##           Value Std.Error DF   t-value p-value
## (Intercept) 24.023148 0.4296608 80 55.91189      0
## I(age - 11)  0.660185 0.0712532 80  9.26534      0
## Correlation:
##           (Intr)
## I(age - 11) 0.294
##
## Standardized Within-Group Residuals:
##           Min           Q1           Med           Q3           Max
## -3.223106430 -0.493761203  0.007316812  0.472151146  3.916034259
##
## Number of Observations: 108
## Number of Groups: 27

fm1Orth.lme <- lme( fm2Orth.lis )
summary(fm1Orth.lme)

## Linear mixed-effects model fit by REML
##   Data: Orthodont
##       AIC      BIC    logLik
##   454.6367 470.6173 -221.3183
##
## Random effects:
##   Formula: ~I(age - 11) | Subject
##   Structure: General positive-definite, Log-Cholesky parametrization
##           StdDev   Corr
## (Intercept) 2.1343294 (Intr)
## I(age - 11) 0.2264278 0.503
## Residual    1.3100400
##
## Fixed effects: distance ~ I(age - 11)

```

```
##              Value Std.Error DF   t-value p-value
## (Intercept) 24.023148 0.4296602 80 55.91197      0
## I(age - 11) 0.660185 0.0712533 80 9.26533      0
## Correlation:
##              (Intr)
## I(age - 11) 0.294
##
## Standardized Within-Group Residuals:
##              Min              Q1              Med              Q3              Max
## -3.22310613 -0.49376096 0.00731653 0.47215112 3.91603230
##
## Number of Observations: 108
## Number of Groups: 27
```

Uma vantagem de utilizar a ultima forma de implementar o modelo é que as estimativas iniciais para os parâmetros na verossimilhança perfilada (restrita), do modelo de efeitos mistos, são calculadas automaticamente a partir do objeto `lmList`.

Uma das questões de interesse relativa aos dados de crescimento ortodôntico é se meninos e meninas têm padrões de crescimento diferentes.⁷ Esta questão pode ser avaliada ajustando o modelo

⁷ Observe que o `lmList` não pode ser usado para testar diferenças de gênero nos dados de crescimento ortodôntico, pois estima coeficientes individuais para cada sujeito.

```
fm20rth.lme <- update(fm10rth.lme, fixed = distance~Sex*I(age-11)-1)
summary(fm20rth.lme)

## Linear mixed-effects model fit by REML
##   Data: Orthodont
##       AIC      BIC    logLik
## 448.5817 469.7368 -216.2908
##
## Random effects:
## Formula: ~I(age - 11) | Subject
## Structure: General positive-definite, Log-Cholesky parametrization
##              StdDev    Corr
## (Intercept) 1.8303271 (Intr)
## I(age - 11) 0.1803454 0.206
## Residual    1.3100396
##
## Fixed effects: distance ~ Sex + I(age - 11) + Sex:I(age - 11) - 1
##              Value Std.Error DF   t-value p-value
## SexMale      24.968750 0.4860008 25 51.37595 0.0000
## SexFemale    22.647727 0.5861390 25 38.63883 0.0000
## I(age - 11)   0.784375 0.0859995 80 9.12069 0.0000
## SexFemale:I(age - 11) -0.304830 0.1347353 80 -2.26243 0.0264
## Correlation:
```

```
##              SexMal SexFml I(-11)
## SexFemale      0.000
## I(age - 11)     0.102  0.000
## SexFemale:I(age - 11) -0.065  0.078 -0.638
##
## Standardized Within-Group Residuals:
##      Min      Q1      Med      Q3      Max
## -3.168078588 -0.385939131  0.007103648  0.445154526  3.849463491
##
## Number of Observations: 108
## Number of Groups: 27
```

Os pequenos valores de p associados a Sex e $Sex : I(age - 11)$ no resultado do summary indicam que meninos e meninas têm padrões de crescimento ortodôntico significativamente diferentes.

A função `fitted` é usado para extrair os valores ajustados do objeto `lme`. Por padrão, os valores ajustados dentro do grupo, ou seja, os valores ajustados correspondentes às estimativas dos coeficientes individuais, são produzidos. Os valores preditos à população, baseados apenas nas estimativas de efeitos fixos, são obtidos definindo o argumento `level=0`. Ambos os tipos de valores ajustados podem ser obtidos simultaneamente com:

```
fm20rth.lme$coefficients$fixed

##              SexMale      SexFemale      I(age - 11)
##              24.9687500      22.6477273      0.7843750
## SexFemale:I(age - 11)
##              -0.3048295

fm20rth.lme$coefficients$random$Subject[c(1:5,17), ]

##      (Intercept) I(age - 11)
## M16  -1.758374 -0.08864715
## M05  -1.738555 -0.00847416
## M02  -1.411531 -0.02356274
## M11  -1.219939 -0.14051911
## M07  -1.077900 -0.01192699
## F10  -3.673842 -0.06269744
```

Vamos considerar duas crianças M16 e F10, avaliados aos 8 anos

```
coefficients(fm20rth.lme)[c(1,17), ]

##      SexMale SexFemale I(age - 11) SexFemale:I(age - 11) (Intercept)
## M16 24.96875  22.64773  0.6957278      -0.3048295  -1.758374
## F10 24.96875  22.64773  0.7216776      -0.3048295  -3.673842
```


$$\begin{aligned}\widehat{y_{t,M16}} &= (24.9687500 - 1.758374) - 2.3210227 \text{SexFemale} + (0.7843750 - 0.088647147)I(\text{age} - 11) \\ &\quad - 0.3048295 \text{SexFemale} : I(\text{age} - 11) \\ &= 23.21038 + 0.6957279I(\text{age} - 11)\end{aligned}$$

para 8 anos

$$\begin{aligned}\widehat{y_{t=-3,M16}} &= 23.21038 + 0.6957279(-3) \\ \widehat{y_{t=-3,M16}} &= 21.1232\end{aligned}$$

e

$$\begin{aligned}\widehat{y_{t,F10}} &= (24.9687500 - 3.673842) - 2.3210227 \text{SexFemale} + (0.7843750 - 0.062697440)I(\text{age} - 11) \\ &\quad - 0.3048295 \text{SexFemale} : I(\text{age} - 11) \\ &= 21.29491 - 2.3210227 \text{SexFemale} + 0.7216776I(\text{age} - 11) - 0.3048295 \text{SexFemale} : I(\text{age} - 11) \\ &= 18.97389 + 0.4168481I(\text{age} - 11)\end{aligned}$$

para 8 anos

$$\begin{aligned}\widehat{y_{t=-3,F10}} &= 18.97389 + 0.4168481(-3) \\ \widehat{y_{t=-3,F10}} &= 17.72335\end{aligned}$$

Conferindo as estimativas obtidas com a saída do R:

```
predict(fm20rth.lme)[c(61, 101)]

##      M16      F10
## 21.12319 17.72334

fitted( fm20rth.lme, level = 0 )[c(61, 101)] # sem efeito aleatório

##      M16      F10
## 22.61562 21.20909

fitted( fm20rth.lme, level = 1 )[c(61, 101)] # com efeito aleatório

##      M16      F10
## 21.12319 17.72334
```

Obtendo somente os efeitos aleatórios para as crianças M16 e F10:

```
ef<- ranef(fm20rth.lme)
ef[c(1, 17), ]
```




Figure 4: Crescimento dentário (mm) ajustado por fm2Orth.lme, efeito aleatório para intercepto e coeficiente angular

```
##      (Intercept) I(age - 11)
## M16    -1.758374 -0.08864715
## F10    -3.673842 -0.06269744
```

Os resíduos são extraídos com a função `resid`, que também usa um argumento de `(level)`.⁸

```
resid( fm2Orth.lme, level = 0 )[c(61, 101)] # sem efeito aleatório
```

```
##      M16      F10
## -0.615625 -4.709091
```

```
resid( fm2Orth.lme, level = 1 )[c(61, 101)] # com efeito aleatório
```

```
##      M16      F10
##  0.8768074 -1.2233409
```

A função `compareFits` pode ser usada para uma comparação dos parâmetros fixos para cada indivíduo. A saída fornecida por essa função é um (array), veja o caso das crianças M16 e F10:

```
compOrth <- compareFits( coef(fm2Orth.lis), coef(fm10Orth.lme) )
compOrth["M16",1:2,1:2]
```

⁸ Os resíduos padronizados ou de Pearson, correspondentes aos resíduos brutos divididos pelo desvio padrão estimado dentro do grupo, são obtidos usando o argumento `type = "pearson"`

```
## (Intercept) I(age - 11)
## coef(fm2Orth.lis)      23.000  0.5500000
## coef(fm1Orth.lme)      23.078  0.5913314
```

```
compOrth["F10",1:2,1:2]
```

```
## (Intercept) I(age - 11)
## coef(fm2Orth.lis)      18.50000  0.4500000
## coef(fm1Orth.lme)      18.98527  0.4095941
```




Figure 5: Comparativo entre as estimativas dos parâmetros de efeitos fixos do modelo sem e com efeitos aleatórios

Em seu material, na página 26, Arnab Maity de ajustou o modelo a que ele chamou de **{Model A}**, aqui iremos ajustar o mesmo modelo porém com parametrização diferente.

```
fit.a <- lme(fixed = distance ~ -1 + G + G:age + M + M:age,
            random = ~ age | id, data = dental, method = "ML")

fit.a2 <- lme(fixed = distance ~ -1 + Sex + I(age) + Sex:I(age),
            random = ~ age | id, data = dental, method = "ML")

fit.a3 <- lme(fixed = distance ~ -1 + Sex + I(age - 11) + Sex:I(age - 11),
            random = ~ age | id, data = dental, method = "ML")
```

```
fit.a4 <- lme(fixed = distance ~ Sex + I(age) + Sex:I(age),
             random = ~ age | id, data = dental, method = "ML")
```

```
fit.a5 <- lme(fixed = distance ~ Sex + I(age - 11) + Sex:I(age - 11),
             random = ~ age | id, data = dental, method = "ML")
```

Primeiramente podemos verificar que o `llogLik` e o `AIC`, são iguais para as três formas de implementar:

```
(LogLik<- c(logLik(fit.a ),logLik(fit.a2),logLik(fit.a3),logLik(fit.a4),logLik(fit.a5)))
```

```
## [1] -213.903 -213.903 -213.903 -213.903 -213.903
```

```
(AIC<- c(AIC(fit.a ),AIC(fit.a2),AIC(fit.a3),AIC(fit.a4),AIC(fit.a5)))
```

```
## [1] 443.806 443.806 443.806 443.806 443.806
```

Os `summary` dos seis ajustes apresentam os mesmos resultados sobre **Random effects**:, como era esperado. Com os resultados obtidos podemos escrever as matrizes G e R , dadas em (2).⁹

Random effects:

Formula: ~age | id

Structure: General positive-definite, Log-Cholesky

	StdDev	Corr
(Intercept)	2.134688	(Intr)
age	0.154139	-0.603
Residual	1.310040	

Vejamos agora como são apresentados os efeitos fixos do modelo:

```
# fit.a
```

```
fixed.effects(fit.a)
```

```
##           G           M           G:age           age:M
## 17.3727273 16.3406250  0.4795455  0.7843750
```

Girls ($G = 1$) : $\hat{\mu}(age) \approx 17.373 + 0.48age$

Boys ($G = 0$) : $\hat{\mu}(age) \approx 16.341 + 0.784age$.

```
# fit.a2
```

```
fixed.effects(fit.a2)
```

```
##           SexMale           SexFemale           I(age) SexFemale:I(age)
##          16.3406250          17.3727273          0.7843750          -0.3048295
```

$$\begin{aligned} cov(b_i) &= D = \begin{pmatrix} D_{11} & D_{12} \\ D_{12} & D_{22} \end{pmatrix} \\ &= \begin{pmatrix} 2.13^2 & -0.603 \times 2.13^2 \times 0.15^2 \\ -0.603 \times 2.13^2 \times 0.15^2 & 0.15^2 \end{pmatrix} \\ &= \begin{pmatrix} 4.56 & -0.60 \\ -0.60 & 0.024 \end{pmatrix}, \end{aligned}$$

a matriz G será bloco diagonal. Temos $\sigma = 1.31$, então

$$R_i = \begin{pmatrix} 1.72 & & & \\ & 1.72 & & \\ & & 1.72 & \\ & & & 1.72 \end{pmatrix}$$

Girls ($G = 1$) : $\hat{\mu}(age) \approx 17.373 + 0.479age$
Boys ($G = 0$) : $\hat{\mu}(age) \approx 16.341 + 0.784age$.

```
# fit.a3
```

```
fixed.effects(fit.a3)
```

```
##           SexMale           SexFemale      I(age - 11)
##           24.9687500           22.6477273           0.7843750
## SexFemale:I(age - 11)
##           -0.3048295
```

Girls ($SexFemale = 1$) : $\hat{\mu}(age) \approx 17.379 + 0.479age$
Boys ($SexFemale = 0$) : $\hat{\mu}(age) \approx 16.345 + 0.784age$.

```
# fit.a4
```

```
fixed.effects(fit.a4)
```

```
##      (Intercept)      SexFemale      I(age) SexFemale:I(age)
##      16.3406250      1.0321023      0.7843750      -0.3048295
```

Girls ($SexFemale = 1$) : $\hat{\mu}(age) \approx 17.373 + 0.479age$
Boys ($SexFemale = 0$) : $\hat{\mu}(age) \approx 16.341 + 0.784age$.

```
# fit.a5
```

```
fixed.effects(fit.a5)
```

```
##      (Intercept)      SexFemale      I(age - 11)
##      24.9687500      -2.3210227           0.7843750
## SexFemale:I(age - 11)
##      -0.3048295
```

Girls ($SexFemale = 1$) : $\hat{\mu}(age) \approx 17.379 + 0.479age$
Boys ($SexFemale = 0$) : $\hat{\mu}(age) \approx 16.345 + 0.784age$.

Como pode ser observado todos os cinco ajustes resultam no mesmo modelo, o que há de diferente é a forma de interpretar as saídas.

```
# fit.a2
```

```
Fixed effects: distance ~ -1 + Sex + I(age) + Sex:I(age)
```

	Value	Std.Error	DF	t-value	p-value
SexMale	16.340625	0.9987521	25	16.361042	0.0000
SexFemale	17.372727	1.2045404	25	14.422702	0.0000
I(age)	0.784375	0.0843294	80	9.301321	0.0000
SexFemale:I(age)	-0.304830	0.1321188	80	-2.307238	0.0236

```
# fit.a4
```

```
Fixed effects: distance ~ Sex + I(age) + Sex:I(age)
```

	Value	Std.Error	DF	t-value	p-value
(Intercept)	16.340625	0.9987521	79	16.361042	0.0000
SexFemale	1.032102	1.5647438	25	0.659598	0.5155
I(age)	0.784375	0.0843294	79	9.301322	0.0000
SexFemale:I(age)	-0.304830	0.1321188	79	-2.307238	0.0237

Note que com o ajuste `fit.a2` podemos testar cada um dos parâmetros de efeito fixo e com `fit.a4` testamos se há diferença para o crescimento médio entre os gêneros. Observe ainda que $17.372727 - 16.340625 = 1.032102$, que é exatamente a estimativa apresentada para `SexFemale` no ajuste `fit.a4`.

Observe a seguir a estrutura de correlação entre os parâmetros em dois modelos que se diferem por ter a variável independente *age* não centralizada e centralizada. A correlação entre os parâmetros de intercepto e inclinação sendo -0.880 e 0.562 para *age* não centralizada e 0.102 e -0.065 para *age* centralizada.

```
# fit.a4
```

```
Fixed effects: distance ~ Sex + I(age) + Sex:I(age)
```

```
Correlation:
```

	(Intr)	SexFml	I(age)
SexFemale	-0.638		
I(age)	-0.880	0.562	
SexFemale:I(age)	0.562	-0.880	-0.638

```
# fit.a5
```

```
Fixed effects: distance ~ Sex + I(age - 11) + Sex:I(age - 11)
```

```
Correlation:
```

	(Intr)	SexFml	I(-11)
SexFemale	-0.638		
I(age - 11)	0.102	-0.065	
SexFemale:I(age - 11)	-0.065	0.102	-0.638

Dado que os modelos são apenas implementados de forma diferente, de acordo com o que deseja-se testar, os resíduos e novas suposições podem seguir do material de Arnab Maity




Figure 6: Plot of Pearson residuals vs. subject-level fitted values for both the groups ($G = 0$: male, and $G = 1$: female) for 'fit.a'.




Figure 7: Plot of Pearson residuals vs. subject-level fitted values for both the groups ($G = 0$: male, and $G = 1$: female) for 'fit.a2'.

Nas Figuras ?? e ?? são apresentados gráficos de resíduos para os ajustes `fit.a` e `fit.a2`, corroborando com o que já foi discutido.